Projekt Dokumentáció:

Útjelző Táblák Felismerése TensorFlow Technológiával

1. Bevezetés

A közlekedésbiztonság és a vezetői segédrendszerek fejlődése napjainkban egyre fontosabbá válik. Ezen projekt célja egy innovatív rendszer kifejlesztése, amely képes az útjelző táblák felismerésére és a rajtuk szereplő információk digitalizálására. A modern képfeldolgozási technikák és gépi tanulási modellek alkalmazásával, mint például a TensorFlow, a rendszer elemzi a közlekedési jelzéseket és azonosítja a szimbólumokat.

Megoldandó Feladat Kifejtése

A projekt fő célja egy olyan modell létrehozása, amely képes felismerni és azonosítani különböző útjelző táblákat. Ez magában foglalja egy interaktív grafikus felhasználói interfész (GUI) kialakítását is, amely lehetővé teszi a felhasználók számára, hogy képeket töltsenek fel és azonnali visszajelzést kapjanak az elemzés eredményeiről.

2. Megoldáshoz Szükséges Elméleti Háttér

Gépi Látás és Képfeldolgozás

A gépi látás a mesterséges intelligencia egy ága, amely a képek és videók automatikus elemzésével és értelmezésével foglalkozik. Ennek alapja a képfeldolgozás, amely magában foglalja a digitális képek különböző módszerekkel történő feldolgozását és elemzését. A képfeldolgozás alapvető lépései közé tartozik a képek előfeldolgozása, zajszűrés, éldetektálás és szegmentáció.

TensorFlow és Mély Tanulás

ábra 1 TrensorFlow logó

A TensorFlow egy nyílt forráskódú szoftverkönyvtár, amelyet a Google fejlesztett ki a gépi tanulás és mély tanulás alkalmazására. A TensorFlow lehetővé teszi a különböző neurális hálózati modellek egyszerű és hatékony kialakítását, tréningelését és kiértékelését. A mély tanulás alapja a mély neurális hálózatok alkalmazása, amelyek több rétegen keresztül képesek a bemenetekből komplex jellemzőket kinyerni és értelmezni.

A TensorFlow különböző eszközöket és könyvtárakat biztosít a modellek építéséhez, tréningeléséhez és implementálásához. Például a Keras magas szintű API-t használja, amely egyszerűsíti a modellek definiálását és tréningelését, valamint lehetővé teszi a GPU-k és TPU-k kihasználását a számítási feladatok felgyorsításához. A TensorFlow.js segítségével böngészőben is futtathatunk modelleket, míg a TensorFlow Lite lehetővé teszi a modellek futtatását mobil és beágyazott eszközökön.

A TensorFlow támogatja a különböző típusú neurális hálózatokat, mint például a konvolúciós neurális hálózatokat (CNN-ek), amelyek különösen hatékonyak képfelismerési feladatokban, valamint a rekurzív neurális hálózatokat (RNN-ek), amelyek időbeli adatokat dolgoznak fel, mint például a beszédfelismerés és a természetes nyelvi feldolgozás.

A TensorFlow használata egyszerűen elkezdhető a hivatalos TensorFlow weboldalon található tutorialok és útmutatók segítségével, amelyek bemutatják, hogyan lehet adatokat betölteni, modelleket építeni és tréningelni, valamint értékelni a modellek teljesítményét.

Érdemes megtekinteni a következő forrásokat:

- [TensorFlow hivatalos weboldal](https://www.tensorflow.org)

- [Coursera TensorFlow kurzus](https://www.coursera.org/learn/introduction-tensorflow)

- [Machine Learning Mastery bevezető](https://machinelearningmastery.com/tensorflow-tutorial-deep-learning/)

3. A Megvalósítás Terve és Kivitelezése

Adatgyűjtés és Előkészítés

A projekt sikeres megvalósításának egyik alapvető lépése az adatok összegyűjtése és előkészítése. Mivel a modellünk különböző útjelző táblákat fog felismerni, fontos, hogy minden típusú táblához megfelelő mennyiségű és minőségű kép álljon rendelkezésre. Az adatok minősége és mennyisége közvetlenül befolyásolja a modell teljesítményét és pontosságát.

Adatgyűjtés

Az adatgyűjtés során különböző forrásokból származó képeket használtam fel, beleértve a nyilvánosan elérhető adatbázisokat, mint például a GTSRB (German Traffic Sign Recognition Benchmark) és a Chinese Traffic Sign Database.

Az adatgyűjtés során különös figyelmet fordítottam arra, hogy minden tábla különböző nézőpontokból és környezetben legyen ábrázolva. Ez magában foglalta a nappali és éjszakai

képeket, valamint különböző távolságokat és szögeket. Ezek az eltérések segítenek a modellnek abban, hogy robusztusabbá váljon és jobban teljesítsen a valós környezetben a későbbiekben.

Adatok Előkészítése

Az adatok előkészítése során a képeket először normalizáltam, hogy egységes méretűek és formátumúak legyenek. Ez magában foglalta a képek átméretezését 30x30 pixeles méretre, valamint a színcsatornák standardizálását. Az előkészítés során a képeket szürkeárnyalatos formátumba is konvertáltam, mivel a színek nem minden esetben jelentettek hozzáadott értéket a tábla felismerésében.

Adat Argumentálás

Az adat argumentálás egy fontos lépés az adatok mennyiségének növelésére és a modell robusztusságának növelésére. Az argumentálás során különböző transzformációkat alkalmaztam a képekre, mint például:

Forgatás: Képek elforgatása különböző szögekkel (pl. -15, 0, +15 fok)

Eltolás: Képek eltolása vízszintes és függőleges irányban

Fényerő és kontraszt módosítása: Képek fényerejének és kontrasztjának növelése vagy csökkentése

Zaj hozzáadása:

Ezek a technikák segítettek abban, hogy a modell jobban alkalmazkodjon a valós környezet változatosságához, és növelték a trénelési adatok számát anélkül, hogy új képeket kellett volna gyűjteni.

Modell Felépítése és Trénelése

A modell felépítésének és trénelésének folyamata több lépésből állt, beleértve az adatok betöltését, az adatok előkészítését, a modell architektúrájának meghatározását, a modell trénelését és a modell kiértékelését.

Ez a adatok előkészítésének lépései a következők szerint vannak a kódrészletemben:

settings.py

Ebben a fájlban két változó van definiálva: `class_id` és `num_images`.

- *`class_id`* egy karakterlánc, amely egy osztályazonosítót jelöl. Kezdetben `'64'` értékre van állítva, ami azt jelenti, hogy a betanítás ezzel az osztállyal kezdődik.

- *`num_images`* értéke `20`, ami azt jelzi, hogy a modellt 20 képpel tesztelem.

trainer.py

Ez a fájl tartalmazza a betanításhoz szükséges fő logikát, beleértve a képek kezelését és az adatok CSV fájlba írását.

```
import cv2
import csv
import os
from data import csv_data
from settings import class_id, num_images
```

- A szükséges modulok importálása

- A `data` modulból importálja a `csv_data` adatokat, a `settings` modulból pedig az `class_id` és `num_images` változókat.

Létező képutak összegyűjtése a Train.csv fájlból

```
def get_existing_image_paths(csv_file_path):
    existing_paths = set()
    try:
        with open(csv_file_path, mode='r', newline='') as file:
            reader = csv.DictReader(file)
            for row in reader:
                existing_paths.add(row['Path'])
    except FileNotFoundError:
        pass  # Ha a Train.csv nem létezik, csak egy üres halmazt ad vissza
    return existing_paths
```

- Ez a függvény összegyűjti a már létező képutakat a `Train.csv` fájlból, és egy halmazban tárolja őket.

Utolsó feldolgozott kép keresése

```
def find_last_processed_image(csv_file_path, class_id):
    max_set_counter = -1
    max_image_counter = -1
    try:
        with open(csv_file_path, mode='r', newline='') as file:
            reader = csv.DictReader(file)
            for row in reader:
                if class_id in row['Path']:
                    parts = row['Path'].split('_')
                    set_counter, image_counter = int(parts[-2]), int(parts[-1].split('.')[0])
                    if set_counter > max_set_counter or (set_counter == max_set_counter and
image_counter > max_image_counter):
                        max_set_counter, max_image_counter = set_counter, image_counter
    except FileNotFoundError:
        pass  # Ha a Train.csv nem létezik, az elejéről indulunk
    return max_set_counter, max_image_counter
```

- Ez a függvény megkeresi az utolsó feldolgozott képet a `Train.csv` fájlban az adott `class_id` alapján.

Képutak érvényesítése

```
def validate_image_paths(image_paths):
    missing_images = [img for img in image_paths if not os.path.exists(img)]
    if missing_images:
        print("A következő képek hiányoznak, és kihagyásra kerülnek:")
        for missing in missing_images:
            print(missing)
    return [img for img in image_paths if os.path.exists(img)]
```

- Ez a függvény ellenőrzi, hogy a megadott képutak léteznek-e, és figyelmeztet, ha hiányzó képeket talál.

Fő kód a képfeldolgozáshoz és CSV fájlba íráshoz

```
class_id_padded = f"{int(class_id):05d}"

output_csv_path = 'output.csv'
train_csv_path = 'Train.csv'  # Az meglévő Train.csv fájl útvonala

base_save_dir = f'Train/{class_id}'
trainer_dir = 'Trainer'

image_paths = [f'{trainer_dir}/{class_id}/image{i+1}.png' for i in range(num_images)]
image_paths += [f'{trainer_dir}/{class_id}/image{i:02d}.png' for i in range(1, num_images+1)]
valid_image_paths = validate_image_paths(image_paths)  # Érvényesítés feldolgozás előtt

last_set_counter, last_image_counter = find_last_processed_image(output_csv_path, class_id)

total_processed_images = last_set_counter * 29 + last_image_counter + 1
num_existing_images = len([img for img in valid_image_paths if os.path.exists(img)])
starting_image_index = total_processed_images - num_existing_images

existing_image_paths = get_existing_image_paths(train_csv_path)

if not os.path.exists(base_save_dir):
    os.makedirs(base_save_dir)

with open(output_csv_path, mode='w', newline='') as output_file, open(train_csv_path, mode='a',
newline='') as train_file:
    output_writer = csv.writer(output_file)
    train_writer = csv.writer(train_file)
    output_writer.writerow(['Width', 'Height', 'Roi.X1', 'Roi.Y1', 'Roi.X2', 'Roi.Y2', 'ClassId',
'Path'])

    set_counter, image_counter = (total_processed_images // 29, total_processed_images % 29) if
total_processed_images > 0 else (0, 0)

    if image_counter >= 0:
        image_counter += 1
        if image_counter >= 29:
            image_counter = 0
            set_counter += 1
    else:
        image_counter = 0
        set_counter = 0 if set_counter == 0 else set_counter + 1

    for idx, image_path in enumerate(valid_image_paths):
        if idx < starting_image_index:
            continue
```

```
        input_image = cv2.imread(image_path)
        if input_image is None:
            print(f"Sikertelen képbetöltés: {image_path}")
            continue

        for width, height, roi_x1, roi_y1, roi_x2, roi_y2, _ in csv_data:
            resized_image = cv2.resize(input_image, (width, height))
            filename = f"{class_id_padded}_{set_counter:05d}_{image_counter:05d}.png"
            relative_path = f"Train/{class_id}/{filename}"
            save_path = os.path.join(base_save_dir, filename)

            if relative_path in existing_image_paths:
                continue

            if not os.path.exists(os.path.dirname(save_path)):
                os.makedirs(os.path.dirname(save_path))

            cv2.imwrite(save_path, resized_image)
            output_writer.writerow([width, height, roi_x1, roi_y1, roi_x2, roi_y2, class_id,
relative_path])
            train_writer.writerow([width, height, roi_x1, roi_y1, roi_x2, roi_y2, class_id,
relative_path])

            image_counter += 1
            if image_counter >= 29:
                image_counter = 0
                set_counter += 1
```

order.py

Ez a fájl egy függvényt tartalmaz a képek átnevezésére egy adott könyvtárban. A **SORRENDISÉG** és a **betanítás** miatt fontos ez a lépés!

```
import os
import glob

def rename_images(directory, extension="png"):
    os.chdir(directory)
    image_files = glob.glob(f"*.{extension}")
    image_files.sort()
    for i, file in enumerate(image_files, start=1):
        new_name = f"image{str(i).zfill(2)}.{extension}"
        os.rename(file, new_name)
        print(f"Átnevezve '{file}' erre: '{new_name}'")

directory_path = 'Trainer/49'
rename_images(directory_path)
```

data.py

Ez a fájl tartalmazza a CSV-ben megadott képek rotációit és transzformációit:

```
csv_data = [
    [27, 26, 5, 5, 22, 20, 20],
    [28, 27, 5, 6, 23, 22, 20],
    [29, 26, 6, 5, 24, 21, 20],
    [28, 27, 5, 6, 23, 22, 20],
    [28, 26, 5, 5, 23, 21, 20],
    [31, 27, 6, 5, 26, 22, 20],
    [31, 28, 6, 6, 26, 23, 20],
    [31, 28, 6, 6, 26, 23, 20],
    [31, 29, 5, 6, 26, 24, 20],
    [34, 32, 6, 6, 29, 26, 20],
    [36, 33, 5, 6, 31, 28, 20],
    [37, 34, 5, 6, 32, 29, 20],
    [38, 34, 5, 6, 32, 29, 20],
    [40, 34, 6, 6, 34, 29, 20],
    [39, 34, 5, 5, 34, 29, 20],
    [42, 36, 6, 5, 37, 31, 20],
    [45, 39, 6, 5, 40, 34, 20],
    [47, 42, 5, 5, 41, 36, 20],
    [50, 45, 5, 5, 45, 40, 20],
    [55, 49, 6, 5, 49, 43, 20],
    [56, 51, 6, 6, 51, 46, 20],
    [59, 54, 5, 5, 54, 49, 20],
    [64, 57, 6, 5, 59, 52, 20],
    [70, 61, 6, 5, 64, 56, 20],
    [76, 69, 6, 6, 70, 63, 20],
    [86, 75, 8, 6, 79, 69, 20],
    [97, 87, 8, 7, 89, 80, 20],
    [111, 100, 9, 8, 102, 92, 20],
    [131, 119, 12, 11, 120, 109, 20], 1 darab kép 29 fajta transzformációja 29 darabbá
]
```

Adatok Betöltése és Előkészítése

Az adatok betöltése és előkészítése során az összegyűjtött és előkészített képeket numpy tömbökbe rendeztük, hogy könnyen felhasználhatók legyenek a TensorFlow által. Az adatokat két fő részre osztottuk: tréning adatokra és teszt adatokra. A tréning adatokkal a modell tanul, míg a teszt adatokkal a modell teljesítményét értékeljük.

Modell Architektúra

A modell architektúrájának meghatározása során a következő rétegeket használtuk, amelyek részletesen bemutatják az egyes rétegek működését és a kimeneti formákat:

Konvolúciós Rétegek (Conv2D)

- **conv2d (Conv2D)**:

  - **Kimeneti alak**: `(None, 26, 26, 32)`

  - **Leírás**: Az első konvolúciós réteg, amely 32 darab, 3x3-as szűrőt használ. Ez a réteg a bemeneti képből (általában 28x28x1 méretű) kinyeri az alapvető jellemzőket.

- **conv2d_1 (Conv2D)**:

  - **Kimeneti alak**: `(None, 22, 22, 32)`

  - **Leírás**: A második konvolúciós réteg, amely szintén 32 darab, 3x3-as szűrőt alkalmaz, további jellemzőket kinyerve a képből.

Max Pooling Rétegek (MaxPooling2D)

- **max_pooling2d (MaxPooling2D)**:

  - **Kimeneti alak**: `(None, 11, 11, 32)`

  - **Leírás**: Ez a réteg 2x2-es ablakokat használ, hogy a térbeli méreteket felezze, csökkentve az adatok számát, és kiemelve a legfontosabb jellemzőket.

Dropout Rétegek (Dropout)

- **dropout (Dropout)**:

  - **Kimeneti alak**: `(None, 11, 11, 32)`

  - **Leírás**: Ez a réteg az overfitting csökkentésére szolgál, véletlenszerűen kinullázva a bemenetek 25%-át (általában).

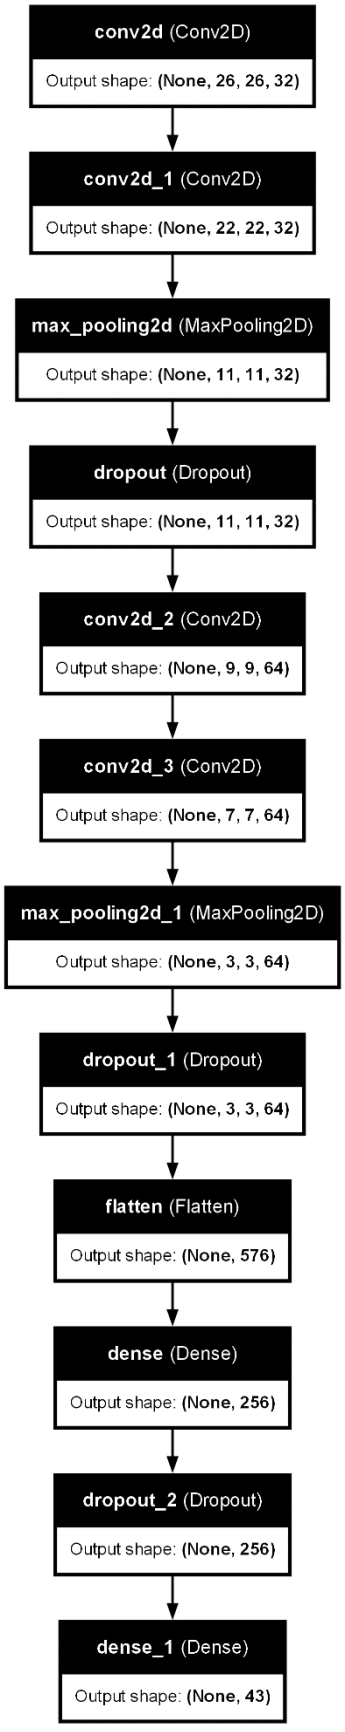

ábra 2. Modell Architektúrája grafikon

További Konvolúciós Rétegek

- **conv2d_2 (Conv2D)**:

  - **Kimeneti alak**: `(None, 9, 9, 64)`

  - **Leírás**: Harmadik konvolúciós réteg, amely 64 darab, 3x3-as szűrőt használ a további jellemzők kinyerésére.

- **conv2d_3 (Conv2D)**:

  - **Kimeneti alak**: `(None, 7, 7, 64)`

  - **Leírás**: Negyedik konvolúciós réteg, amely szintén 64 darab, 3x3-as szűrőt alkalmaz.

Max Pooling és Dropout Rétegek

- **max_pooling2d_1 (MaxPooling2D)**:

  - **Kimeneti alak**: `(None, 3, 3, 64)`

  - **Leírás**: Újabb max pooling réteg, amely 2x2-es ablakokat használ, hogy tovább csökkentse a térbeli méreteket.

- **dropout_1 (Dropout)**:

  - **Kimeneti alak**: `(None, 3, 3, 64)`

  - **Leírás**: További dropout réteg az overfitting csökkentésére.

Flatten Réteg

- **flatten (Flatten)**:

  - **Kimeneti alak**: `(None, 576)`

  - **Leírás**: Ez a réteg a 3D-s adatokat (3x3x64) egy hosszú, egy dimenziós vektorrá alakítja át (576), amelyet a teljesen összekapcsolt rétegekhez használunk.

Teljesen Összekapcsolt Rétegek (Dense)

- **dense (Dense)**:

  - **Kimeneti alak**: `(None, 256)`

  - **Leírás**: Az első teljesen összekapcsolt réteg, amely 256 neuront tartalmaz, és a kinyert jellemzők alapján előfeldolgozást végez.

Modell Trénelése

A modell trénelésének során a fit függvényt használtuk, amely a tréning adatokon végrehajtja a tanulási folyamatot. A trénelés során figyeltük a modell pontosságát és veszteségét az epochok* során, valamint validációs adatokat is használtunk a modell teljesítményének kiértékelésére. A trénelési folyamat több epochon keresztül zajlott, hogy a modell megfelelően megtanulja a bemenetek és a kimenetek közötti kapcsolatot.

*Egy epoch egy teljes iteráció a teljes tréning adathalmaz felett. Ez azt jelenti, hogy az összes tréning adatpontot egyszer feldolgozza a modell, beleértve a súlyok frissítését és a veszteség kiszámítását minden egyes adatpont után

Modell Felépítése és Trénelése

A modell felépítése az adott képek számától függően körülbelül 40 percet vesz igénybe.

Adatok Betöltése és Előkészítése

Az adatok betöltését és előkészítését a `load_training_data` és `load_test_data` függvények végzik.

```
def load_training_data(image_directory, num_classes=images_sum):
    data = []
    labels = []
    for i in range(num_classes):
        path = os.path.join(image_directory, str(i))
        images = os.listdir(path)
        for img in images:
            try:
                img_path = os.path.join(path, img)
                image = Image.open(img_path)
                image = image.resize((30,30))
                image = np.array(image)
                data.append(image)
                labels.append(i)
            except:
                print(f"Error loading image: {img_path}")
    data = np.array(data)
    labels = np.array(labels)
    return data, labels
```

Adatok Szétválasztása

Az adatokat tréning és validációs adathalmazokra osztjuk a `train_test_split` függvény segítségével:

```
X_train, X_val, y_train, y_val = train_test_split(data, labels, test_size=0.2, random_state=42)
y_train = to_categorical(y_train, images_sum)
y_val = to_categorical(y_val, images_sum)
```

Modell Felépítése

A modell felépítéséhez a `build_model` függvényt használjuk, amely egy sor konvolúciós, max pooling és dropout rétegből álló Sequential modellt hoz létre:

```
def build_model(input_shape, num_classes):
    model = Sequential([
        Conv2D(32, (5, 5), activation='relu', input_shape=input_shape),
        Conv2D(32, (5, 5), activation='relu'),
        MaxPool2D(pool_size=(2, 2)),
        Dropout(0.25),
        Conv2D(64, (3, 3), activation='relu'),
        Conv2D(64, (3, 3), activation='relu'),
        MaxPool2D(pool_size=(2, 2)),
        Dropout(0.25),
        Flatten(),
        Dense(256, activation='relu'),
        Dropout(0.5),
        Dense(num_classes, activation='softmax')
    ])
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
    return model
```

Modell Trénelése

A modell trénelése a `fit` függvény segítségével történik, ahol megadjuk a tréning és validációs adathalmazokat, valamint a batch méretet és az epochok számát:

```
history = model.fit(X_train, y_train, batch_size=32, epochs=15, validation_data=(X_val, y_val))
```

Modell Mentése

A betanított modell mentése a `model.save` függvény segítségével történik:

```
model.save("traffic_signs_v10.h5")
```

Teszt Adatok Betöltése és Kiértékelése

A teszt adatok betöltésére és kiértékelésére a következő lépésekben kerül sor:

```
csv_path = 'Train.csv'
X_test, y_test_labels = load_test_data(csv_path)
y_test = to_categorical(y_test_labels, images_sum)

test_loss, test_acc = model.evaluate(X_test, y_test, verbose=2)
print(f"Test accuracy: {test_acc}, Test loss: {test_loss}")
```

Eredmények Megjelenítése

A tréning eredményeinek megjelenítése grafikonok segítségével történik, amelyek az accuracy és loss metrikákat ábrázolják az epochok függvényében:

```
plt.figure(0)
plt.plot(history.history['accuracy'], label='training accuracy')
plt.plot(history.history['val_accuracy'], label='val accuracy')
plt.title('Accuracy')
plt.xlabel('epochs')
plt.ylabel('accuracy')
plt.legend()
plt.show()

plt.figure(1)
plt.plot(history.history['loss'], label='training loss')
plt.plot(history.history['val_loss'], label='val loss')
plt.title('Loss')
plt.xlabel('epochs')
plt.ylabel('loss')
plt.legend()
plt.show()
```

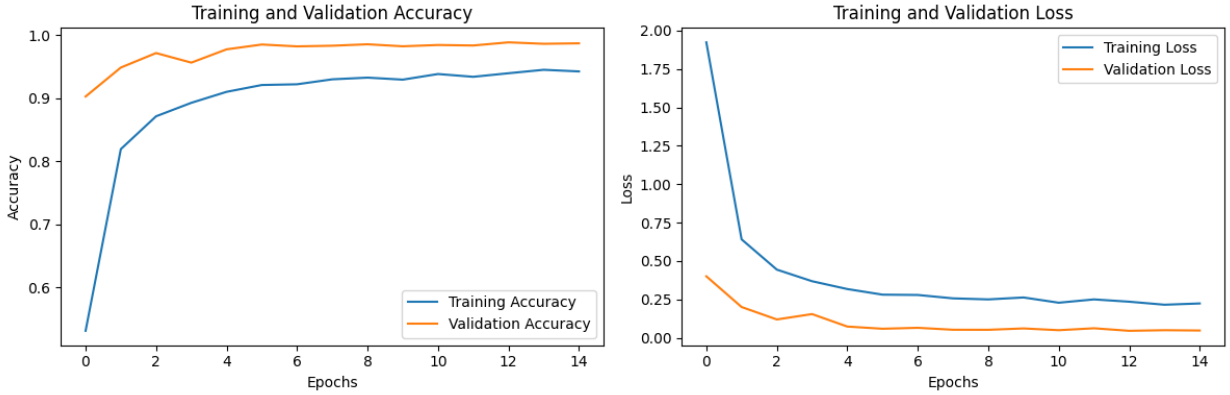

ábra 3 A tréning eredményei

Fő Folyamat

A fő folyamatot a `main` függvény vezérli, amely meghívja a fentebb definiált funkciókat a teljes trénelési és kiértékelési folyamat elvégzésére:

```
def main():
    # Load training data
    image_directory = 'Train'
    data, labels = load_training_data(image_directory)

    # Splitting the dataset
    X_train, X_val, y_train, y_val = train_test_split(data, labels, test_size=0.2, random_state=42)
    y_train = to_categorical(y_train, images_sum)
    y_val = to_categorical(y_val, images_sum)

    # Building and training the model
    model = build_model(X_train.shape[1:], images_sum)
    history = model.fit(X_train, y_train, batch_size=32, epochs=15, validation_data=(X_val, y_val))
```

```
    # Save the model
    model.save("traffic_signs_v10.h5")

    # Load test data
    csv_path = 'Train.csv'
    X_test, y_test_labels = load_test_data(csv_path)
    y_test = to_categorical(y_test_labels, images_sum)

    # Evaluate on test data
    test_loss, test_acc = model.evaluate(X_test, y_test, verbose=2)
    print(f"Test accuracy: {test_acc}, Test loss: {test_loss}")

    # Plotting training results
    plt.figure(0)
    plt.plot(history.history['accuracy'], label='training accuracy')
    plt.plot(history.history['val_accuracy'], label='val accuracy')
    plt.title('Accuracy')
    plt.xlabel('epochs')
    plt.ylabel('accuracy')
    plt.legend()
    plt.show()

    plt.figure(1)
    plt.plot(history.history['loss'], label='training loss')
    plt.plot(history.history['val_loss'], label='val loss')
    plt.title('Loss')
    plt.xlabel('epochs')
    plt.ylabel('loss')
    plt.legend()
    plt.show()

if __name__ == "__main__":
    main()
```

4. Tesztelés

Teszt Adatok Betöltése és Kiértékelése

A teszt adatok betöltésére és kiértékelésére a fent említett lépéseket követjük. Az adatok betöltése után a modell tesztelése és az eredmények kiértékelése történik, amely során megkapjuk a teszt pontosságot és veszteséget.

Tesztelési Eredmények

A tesztelési folyamat során mért pontosság és veszteség értékek fontosak a modell teljesítményének kiértékeléséhez. A következő metrikákat mérjük:

- **Pontosság (Accuracy)**: Az osztályok helyes felismerésének aránya.

- **Veszteség (Loss):** A modell hibájának mértéke.

- **Validációs Pontosság (Val_accuracy):** A validációs adatokon mért pontosság.

- **Validációs Veszteség (Val_loss):** A validációs adatokon mért veszteség.

5. Felhasználói Leírás

Felhasználói Leírás

A grafikus felhasználói felület (GUI) indításához futtasd a fő Python szkriptet a projekt gyökérkönyvtárában:

python gui.py

A GUI-n keresztül töltheted fel az útjelző táblák képeit, amelyeket a rendszer elemez, és azonnali visszajelzést ad a felismerés eredményéről. A felhasználói felület intuitív és könnyen használható, lehetővé téve a felhasználók számára a különböző funkciók egyszerű elérését.

GUI Kód

Az alábbiakban bemutatjuk a GUI kódját, amely a modell betöltését és az útjelző táblák felismerését végzi:

```
import tkinter as tk
from tkinter import filedialog
from tkinter import *
from PIL import ImageTk, Image
import numpy as np
from keras.models import load_model

# Load the trained model to classify signs
model = load_model('traffic_signs_v10.h5')

# Dictionary to label all traffic signs class.
classes = {
    1: 'Sebességkorlátozás (20km/h)',
    2: 'Sebességkorlátozás (30km/h)',
    3: 'Sebességkorlátozás (50km/h)',
    4: 'Sebességkorlátozás (60km/h)',
    5: 'Sebességkorlátozás (70km/h)',
    6: 'Sebességkorlátozás (80km/h)',
    7: 'Sebességkorlátozás Vége (80km/h)',
    8: 'Sebességkorlátozás (100km/h)',
    9: 'Sebességkorlátozás (120km/h)',
    10: 'Előzni tilos',
    11: '3,5 tonnánál nehezebb járművek előzése tilos',
    12: 'Elsőbbségadás kötelező kereszteződésben',
    13: 'Főútvonal',
    14: 'Adjon elsőbbséget',
    15: 'Állj, minden járműnek meg kell állnia',
    16: 'Járművek behajtása tilos',
    17: '3,5 tonnánál nehezebb járművek behajtása tilos',
    18: 'Behajtani tilos',
    19: 'Fokozott óvatosság',
    20: 'Veszélyes bal kanyar',
    21: 'Veszélyes jobb kanyar',
    22: 'Kettős kanyar',
    23: 'Buckás út',
    24: 'Csúszós út',
    25: 'Út szűkület jobbról',
    26: 'Útépítési munkálatok',
    27: 'Közlekedési lámpa',
```

```
    28: 'Gyalogosok',
    29: 'Gyermekátkelő',
    30: 'Kerékpár átkelő',
    31: 'Jeges/havas út',
    32: 'Vadállat-átkelő',
    33: 'Sebesség- és előzési korlátozás vége',
    34: 'Jobbra kanyarodj',
    35: 'Balra kanyarodj',
    36: 'Csak egyenesen',
    37: 'Egyenesen vagy jobbra',
    38: 'Egyenesen vagy balra',
    39: 'Tarts jobbra',
    40: 'Tarts balra',
    41: 'Körforgalom',
    42: 'Előzési tilalom vége',
    43: '3,5 tonnánál nehezebb járművek előzési tilalmának vége',
    44: 'Sebességkorlátozás (90km/h)',
    45: 'Gyalogos átkelőhely - Járda',
    46: 'Sebességkorlátozás (5km/h)',
    47: 'Sebességkorlátozás (15km/h)',
    48: 'Sebességkorlátozás (40km/h)',
    49: 'Jobbra és előre kanyarodni tilos',
    50: 'Gyalogosátkelőhely',
    51: 'Egyenesen haladni tilos',
    52: 'Jobbra kanyarodni tilos',
    53: 'Jobbra és balra kanyarodni tilos',
    54: 'Balra kanyarodni tilos',
    55: 'Előzni tilos',
    56: 'Megfordulni tilos',
    57: 'Gépjárművel behajtani tilos',
    58: 'Dudálni tilos',
    59: 'Sebességkorlátozás Vége (40km/h)',
    60: 'Sebességkorlátozás Vége (50km/h)',
    61: 'Kötelező haladási irány: balra vagy jobbra',
    62: 'Autópálya',
    63: 'Kerékpár pálya',
    64: 'Megfordulás kötelező',
    65: 'Veszélyt jelző tábla vagy Általános veszély'
}

# Initialise GUI
top = tk.Tk()
top.geometry('800x600')
top.title('Traffic sign classification')
top.configure(background='#CDCDCD')
label = Label(top, background='#CDCDCD', font=('arial', 15, 'bold'))
sign_image = Label(top)

def classify(file_path):
    global label_packed
    image = Image.open(file_path)
    image = image.convert('RGB')  # Convert the image to RGB
    image = image.resize((30, 30))
    image = np.expand_dims(image, axis=0)
    image = np.array(image)
    prediction = model.predict([image])
    pred = np.argmax(prediction, axis=1)[0]  # Get the index of the max value
    sign = classes[pred + 1]
    print(sign)
    label.configure(foreground='#011638', text=sign)

def show_classify_button(file_path):
    classify_b = Button(top, text="Kép szkennelése", command=lambda: classify(file_path), padx=10,
pady=5)
    classify_b.configure(background='#364156', foreground='white', font=('arial', 10, 'bold'))
```

```
    classify_b.place(relx=0.79, rely=0.46)

def upload_image():
    try:
        file_path = filedialog.askopenfilename()
        uploaded = Image.open(file_path)
        uploaded.thumbnail(((top.winfo_width()/2.25), (top.winfo_height()/2.25)))
        im = ImageTk.PhotoImage(uploaded)
        sign_image.configure(image=im)
        sign_image.image = im
        label.configure(text='')
        show_classify_button(file_path)
    except:
        pass

upload = Button(top, text="Tölts fel egy képet", command=upload_image, padx=10, pady=5)
upload.configure(background='#364156', foreground='white', font=('arial', 10, 'bold'))
upload.pack(side=BOTTOM, pady=50)
sign_image.pack(side=BOTTOM, expand=True)
label.pack(side=BOTTOM, expand=True)
heading = Label(top, text="Útjelző tábla jelentése", pady=20, font=('arial', 20, 'bold'))
heading.configure(background='#CDCDCD', foreground='#364156')
heading.pack()

# Force the window to update to calculate dimensions
top.update()

# Add this block where you initialize your GUI components, after defining `sign_image`
placeholder = Image.open('placeholder.png')  # Load the placeholder image
placeholder.thumbnail(((top.winfo_width()/2.25), (top.winfo_height()/2.25)))
placeholder_image = ImageTk.PhotoImage(placeholder)
sign_image.configure(image=placeholder_image)
sign_image.image = placeholder_image

top.mainloop()
```

Részletek a Kódból

1. Modell Betöltése:

```
    model = load_model('traffic_signs_v10.h5')
```

2. Osztályok Definiálása:

   - A `classes` szótár tartalmazza az összes útjelző tábla osztályát és azok magyar nyelvű leírását.

3. Kép Osztályozása:

   - A `classify` függvény végzi a kép osztályozását, és frissíti a GUI-t az eredménnyel.

```
    def classify(file_path):
        prediction = model.predict([image])
        pred = np.argmax(prediction, axis=1)[0]
        sign = classes[pred + 1]
        ...
        label.configure(foreground='#011638', text=sign)
```

4. Kép Feltöltése:

- Az `upload_image` függvény lehetővé teszi a felhasználó számára, hogy képet töltsön fel, és megjeleníti azt a GUI-n.

```
    def upload_image():
        ...
        file_path = filedialog.askopenfilename()
        ...
        show_classify_button(file_path)
```

5. **GUI Beállítások**:

- A GUI beállításait a Tkinter könyvtár segítségével hoztuk létre, ahol gombok, címkék és képek jelennek meg.

A felhasználók könnyedén feltölthetnek képeket, amelyek alapján a rendszer azonnali visszajelzést ad az útjelző táblák felismeréséről. A magyar nyelvű osztályok segítenek abban, hogy a felhasználók pontosan megértsék az eredményeket.

6. Jövőbeli lehetőségek és ötletek a modell kapcsán

NVIDIA TensorFlow GPU Használata

Az egyik jövőbeli lehetőség a modell futtatásának optimalizálása az NVIDIA TensorFlow GPU segítségével. A TensorFlow GPU verziójának használata számos előnnyel járhat:

1. Gyorsabb Modell Betanítás: A GPU-k párhuzamos feldolgozási képességei lehetővé teszik a modell gyorsabb betanítását, különösen nagyobb adathalmazok esetén.
2. Valós Idejű Feldolgozás: Az útjelző táblák valós idejű felismerése gyorsabbá válik, ami különösen fontos lehet az élő kamera képek feldolgozásánál.
3. Nagyobb Hatékonyság: Az NVIDIA GPU-k speciálisan optimalizáltak mélytanulási feladatokra, így a számítási hatékonyság növekszik, csökkentve az energiafogyasztást és a feldolgozási időt.

A TensorFlow GPU beállítása során szükség van az NVIDIA CUDA és cuDNN könyvtárak telepítésére, valamint a TensorFlow megfelelő verziójának használatára.

3D Kamerák Használata

A jövőbeni fejlesztési tervek között szerepel az Intel RealSense 3D kamerák vagy egyéb 3D kamerák integrálása. Ezek a kamerák lehetővé teszik a mélységi információk és a színes képek együttes használatát, amely számos előnnyel járhat:

ábra 4 Intel Realsense 3D kamera

1. **Pontosság Növelése**: A 3D információk használata lehetővé teszi a pontosabb tárgyfelismerést és a különböző tárgyak könnyebb megkülönböztetését.

2. **Valós Idejű Felismerés**: Az élő kamera kép alapján történő valós idejű táblafelismerés segíthet a közlekedési helyzetek gyorsabb és pontosabb értelmezésében.

3. **Környezet Felismerése**: A mélységi érzékelés lehetővé teszi a kamera számára, hogy a környezet háromdimenziós képét is figyelembe vegye, ami hasznos lehet például az autonóm járművek navigációjánál.

GPU Használata az Élő Kamera Kép Feldolgozásához

A 3D kamerák és a GPU-k együttes használata további lehetőségeket nyit meg:

1. Valós Idejű Objektumfelismerés: Az NVIDIA GPU-k párhuzamos feldolgozási képességeinek köszönhetően a valós idejű objektumfelismerés hatékonyabbá válik, ami fontos az élő videó stream feldolgozásánál.

2. Komplex Számítások Gyors Végrehajtása: A mélységi és színes képek együttes feldolgozása jelentős számítási kapacitást igényel, amelyet a GPU-k képesek hatékonyan kezelni.

3. Adaptív Rendszerek: Az élő kamera képek valós idejű feldolgozása lehetővé teszi adaptív rendszerek kialakítását, amelyek valós időben képesek reagálni a változó környezeti feltételekre.

Összefoglalás

A jövőbeni fejlesztések során az NVIDIA TensorFlow GPU és a 3D kamerák használata jelentős előrelépést jelenthet a modell teljesítményében és funkcionalitásában. Ezek az újítások lehetővé teszik a gyorsabb, pontosabb és hatékonyabb táblafelismerést, különösen valós idejű alkalmazásokban.

7. Irodalomjegyzék

- [TensorFlow hivatalos weboldala](https://www.tensorflow.org/)

- [OpenCV dokumentáció](https://opencv.org/)

- [PIL (Pillow) dokumentáció](https://pillow.readthedocs.io/)

- [Pytesseract GitHub oldala](https://github.com/madmike/ocr-Template-matching)

- [GTSRB (German Traffic Sign Recognition Benchmark) dataset a Kaggle-on](https://www.kaggle.com/datasets/meowmeowmeowmeowmeow/gtsrb-german-traffic-sign)

- [Chinese Traffic Sign Database](https://nlpr.ia.ac.cn/pal/trafficdata/recognition.html)

- [DFG Resources](https://www.vicos.si/resources/dfg/)

Ez a dokumentáció részletesen bemutatja az útjelző táblák felismerésére irányuló projektet, beleértve a szükséges elméleti hátteret, a megvalósítás részleteit, a tesztelési folyamatot és a felhasználói útmutatót. A projekt célja, hogy egy olyan rendszert hozzon létre, amely képes pontosan felismerni és digitalizálni az útjelző táblák információit, támogatva ezzel a közlekedésbiztonságot és a vezetők döntéshozatalát.

Tartalom